

Automatización en la Asignación de Tareas en un ERP para Talleres Industriales utilizando Algoritmos Genéticos



Pontificia Universidad
JAVERIANA
Cali

[VIGILADA MINEDUCACIÓN Res. 1229 de 2016.]

Maria José Pava Echeverry

Jose Daniel Ramirez Delgado

Directora:

PhD. Gloria Ines Alvares Vargas

Co-director:

PhD. Diego Luis Linares Ospina

FACULTAD DE INGENIERÍA Y CIENCIAS
INGENIERÍA DE SISTEMAS Y COMPUTACIÓN

Pontificia Universidad Javeriana Cali

Santiago de Cali, 2025

Contents

1	Introducción	1
2	Definición y Planteamiento del Problema	3
2.1	Planteamiento del Problema	3
2.1.1	Formulación	4
2.1.2	Sistematización	4
2.2	Objetivos	4
2.2.1	Objetivo General	4
2.2.2	Objetivos Específicos	5
2.3	Justificación	5
2.4	Delimitaciones y Alcances	6
3	Marco de Referencia	7
3.1	Marco Teórico	7
3.1.1	Automatización con ERP en talleres industriales . . .	8
3.1.2	Algoritmos Genéticos (GA) para la Automatización . .	8
3.2	Técnicas de Automatización en Ingeniería Industrial	9
3.2.1	Lean Manufacturing y mejora continua	9
3.2.2	Six Sigma y reducción de variabilidad	10
3.2.3	Investigación de Operaciones aplicada al Scheduling . .	10
3.2.4	Reglas de prioridad (Dispatching Rules)	11
3.2.5	Métodos heurísticos clásicos	12
3.2.6	Metaheurísticas aplicadas al scheduling	13
3.2.7	Métodos deterministas y exactos	13
3.3	Antecedentes	14
4	Formalización del problema	16
4.1	Estudio del flujo de trabajo del taller industrial	16

4.1.1	Tipos de tareas	16
4.1.2	Operarios y recursos disponibles	17
4.1.3	Reglas industriales de asignación	17
4.1.4	Análisis del proceso actual y puntos críticos	18
4.1.5	Flujo general del proceso	18
4.2	Diseño del modelo de datos para la simulación	19
4.2.1	Conjuntos y parámetros del sistema	19
4.2.2	Variables del modelo	19
4.2.3	Representación de operarios, tareas y repuestos	19
4.2.4	Tiempos de operación y estructura temporal	20
4.2.5	Restricciones formales del taller	20
4.3	Construcción del generador de instancias	20
4.3.1	Parámetros de la simulación y alcance	20
4.3.2	Modelo de aleatoriedad y distribución de tiempos	21
4.3.3	Procedimiento de creación de escenarios	21
4.3.4	Validación del modelo simulado con expertos	21
4.3.5	Pseudocódigo del simulador operativo	22
4.4	Conjunto final de escenarios utilizados en la comparación	22
4.4.1	Número y estructura de las instancias	22
4.4.2	Variabilidad incorporada	23
4.4.3	Justificación de los casos de estudio	23
5	Desarrollo de la Solución	24
5.1	Modelado del Problema como Problema de Optimización	24
5.1.1	Variables	24
5.1.2	Restricciones	25
5.1.3	Función Objetivo	25
5.2	Diseño del Algoritmo Genético	25
5.2.1	Representación	26
5.2.2	Selección	26
5.2.3	Cruce	26
5.2.4	Mutación	26
5.2.5	Parámetros	26
5.3	Implementación del Método SPT	27
5.4	Integración con el Entorno Simulado	27
5.5	Arquitectura General del Sistema Desarrollado	27

6	Implementación	28
6.1	Entorno de desarrollo	28
6.2	Diseño del software	29
6.2.1	Arquitectura general del sistema	29
6.2.2	Flujo general del software	29
6.3	Implementación del algoritmo genético	30
6.3.1	Representación del individuo	30
6.3.2	Generación del espacio de búsqueda	30
6.3.3	Función de aptitud	31
6.3.4	Integración con PyGAD	31
6.4	Implementación del método SPT	32
6.4.1	Ordenamiento de tareas	32
6.4.2	Asignación de operarios y validación	32
6.5	Ejecución de simulaciones	32
6.5.1	Generación de conjuntos de instancias	33
6.5.2	Ejecución conjunta de SPT y AG	33
6.5.3	Consolidación de resultados	33
6.5.4	Reproducibilidad	33
6.5.5	Evaluación del Operador de Cruce	34
6.5.6	Evaluación del Número de Generaciones	35
6.5.7	Evaluación de la Probabilidad de Mutación	36
6.6	Configuración Final del AG	37
7	Análisis de Resultados	39
7.1	Métricas utilizadas	40
7.1.1	Tareas ejecutadas	40
7.1.2	Tareas rechazadas	40
7.1.3	Sobrecarga (carga total)	40
7.1.4	Balance de carga (desviación estándar)	40
7.1.5	Makespan	40
7.2	Comparación AG vs SPT	40
7.2.1	Descripción general de los resultados	40
7.2.2	Análisis de distribución	40
7.2.3	Tareas ejecutadas y rechazadas	40
7.2.4	Sobrecarga vs eficiencia del sistema	40
7.2.5	Balance entre operarios	40
7.2.6	Ventajas y desventajas de cada enfoque	40
7.3	Discusión de resultados	40

8 Conclusiones	41
8.1 Cumplimiento de objetivos	41
8.2 Conclusiones técnicas	41
8.3 Impacto industrial	41
9 Trabajo Futuro	42
9.1 Optimización del algoritmo genético	42
9.2 Sistemas híbridos	42
9.3 Integración con el ERP	42
9.4 Pruebas con datos reales históricos	42
10 Glosario	43

List of Figures

List of Tables

6.1	Resultados promedio del AG para cada operador de cruce (480 minutos).	34
6.2	Resultados promedio del AG para distintos números de generaciones (480 minutos).	35
6.3	Resultados promedio del AG para diferentes probabilidades de mutación (480 minutos).	36
6.4	Configuración final seleccionada para el algoritmo genético. . .	38

Chapter 1

Introducción

El presente proyecto de grado se centra en abordar los desafíos que enfrentan los talleres industriales en la gestión eficiente de sus operaciones, específicamente en la asignación de tareas dentro de un sistema de Planificación de Recursos Empresariales (ERP). La asignación tradicional de tareas, frecuentemente realizada de forma manual, puede conducir a ineficiencias significativas, tales como la sobrecarga de operarios, tiempos muertos en la producción y retrasos en las entregas, afectando directamente la productividad y la rentabilidad del taller.

En este contexto, la automatización de la asignación de tareas emerge como una solución crucial para optimizar el uso de los recursos y mejorar el flujo de trabajo. Este proyecto propone el desarrollo de un modelo de automatización basado en algoritmos genéticos, una técnica de inteligencia artificial que ha demostrado su eficacia en la resolución de problemas complejos de optimización. Al implementar algoritmos genéticos en el módulo de gestión de órdenes de trabajo de un ERP, se busca automatizar la distribución de tareas considerando variables clave como las capacidades técnicas de los operarios, la disponibilidad de insumos y la carga de trabajo actual.

Además de desarrollar este modelo de automatización, el proyecto tiene como objetivo evaluar su desempeño en comparación con otras técnicas de automatización utilizadas en el campo de la ingeniería industrial. Esta comparación permitirá validar la eficacia y aplicabilidad del enfoque propuesto en un entorno industrial real, asegurando la selección de la estrategia más adecuada para la optimización de la asignación de tareas.

La investigación se llevará a cabo en colaboración con la empresa Rectificadora Recti-Ram, lo que proporcionará un contexto real y datos relevantes

para el desarrollo y la validación del modelo.

A través de este proyecto, se espera contribuir al avance en la automatización de los talleres industriales, proporcionando una herramienta que permita mejorar la eficiencia operativa, reducir los costos y aumentar la satisfacción del cliente mediante la optimización de los procesos de asignación de tareas.

Chapter 2

Definición y Planteamiento del Problema

2.1 Planteamiento del Problema

El entorno productivo de los talleres industriales enfrenta diversas problemáticas que afectan su eficiencia y rendimiento. Entre los principales desafíos se encuentran la capacidad de producción limitada, los largos tiempos de fabricación y los retrasos en las fechas de entrega [1]. Además, la falta de sistemas estructurados para la evaluación de calidad y la baja integración tecnológica pueden impactar negativamente la productividad del proceso [1].

La asignación de tareas en los talleres industriales es un factor clave para optimizar el uso de recursos humanos y técnicos. Una planificación ineficiente puede provocar retrasos, una distribución desequilibrada de la carga de trabajo y una reducción en la productividad [2]. La complejidad de estos entornos productivos, caracterizados por la variabilidad en la demanda y la necesidad de coordinar múltiples operaciones, hace necesario el uso de enfoques avanzados que permitan gestionar eficazmente la distribución de actividades y mejorar el cumplimiento de los plazos de entrega [2].

Para abordar este problema, se propone la implementación de algoritmos genéticos (AG) en un módulo ERP de gestión de órdenes de trabajo. Esta solución permitirá automatizar la distribución de tareas considerando factores clave como:

- Capacidades técnicas de cada operario.

- Disponibilidad de insumos requeridos para cada tarea.
- Carga de trabajo actual y disponibilidad horaria de los operarios.

Adicionalmente, este estudio evaluará el desempeño del algoritmo genético en comparación con otro método de optimización utilizado en ingeniería industrial, con el objetivo de determinar su viabilidad y eficacia en este contexto.

2.1.1 Formulación

¿Cómo mejorar la asignación de tareas en un ERP de talleres industriales utilizando algoritmos genéticos, y cómo se compara su rendimiento con otras técnicas de automatización utilizadas en ingeniería industrial?

2.1.2 Sistematización

Para abordar de manera integral el problema de investigación, se plantean las siguientes preguntas:

1. ¿Cuáles son los principales factores que afectan la asignación de tareas en talleres industriales?
2. ¿Cómo pueden los algoritmos genéticos mejorar la automatización de tareas dentro del ERP?
3. ¿Qué otras técnicas de automatización existen en ingeniería industrial para resolver problemas similares?
4. ¿Cómo se comparan los resultados obtenidos con algoritmos genéticos respecto a otra técnica de automatización en términos de eficiencia y calidad de la solución?

2.2 Objetivos

2.2.1 Objetivo General

Desarrollar un modelo de automatización basado en algoritmos genéticos para apoyar en el módulo de asignación de tareas de un sistema ERP de talleres industriales, comparándolo con otro método de automatización utilizado en ingeniería industrial.

2.2.2 Objetivos Específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

1. Identificar las características claves que influyen en la asignación de tareas en talleres industriales.
2. Diseñar e implementar un modelo utilizando un algoritmo genético para automatizar la asignación de tareas tales como desmontaje del motor, limpieza y diagnóstico, rectificación de cilindros, rectificación de cigüeñales, ajuste de válvulas, ensamblaje y prueba del motor.
3. Evaluar la funcionalidad del modelo y el desempeño del algoritmo genético en comparación con otras técnicas de automatización utilizadas en ingeniería industrial.
4. Analizar los beneficios y limitaciones de los algoritmos genéticos en este contexto.

2.3 Justificación

La gestión eficiente de órdenes de trabajo en talleres industriales impacta directamente la productividad y rentabilidad. El uso de algoritmos genéticos puede ofrecer una solución flexible y adaptable que automatiza los tiempos de ejecución, minimiza costos y mejora la distribución equitativa de la carga de trabajo.

La empresa Rectificadora Recti-Ram cuenta con datos históricos sobre tiempos de reparación, asignación de operarios y disponibilidad de recursos, lo que facilita el entrenamiento y validación del modelo propuesto. Asimismo, la disponibilidad de la empresa para proporcionar información clave sobre su flujo de trabajo y sus restricciones operativas permitirá diseñar un modelo que se ajuste a las necesidades reales.

Además, comparar esta solución con otro método de automatización permitirá validar su aplicabilidad en escenarios industriales reales, asegurando que la mejor estrategia sea implementada dentro del ERP del taller, garantizando así una planificación eficiente y adaptable a las condiciones dinámicas del entorno productivo.

2.4 Delimitaciones y Alcances

- Se enfocará en la asignación de tareas dentro del módulo de ordenes de trabajo en un ERP para talleres industriales.
- Se implementará un modelo basado en algoritmos genéticos.
- Se comparará con otro método de automatización (a definir en consulta con expertos en ingeniería industrial).

Chapter 3

Marco de Referencia

3.1 Marco Teórico

Para comprender el desarrollo de un módulo de ERP destinado a la automatización de la asignación de tareas en un taller industrial, es esencial establecer una base teórica sólida sobre los conceptos clave involucrados. Este proyecto se enfoca en la aplicación de algoritmos genéticos como una técnica de inteligencia artificial que permite la automatización de procesos de toma de decisiones en entornos industriales. Los algoritmos genéticos permiten analizar múltiples combinaciones posibles para la asignación de recursos y actividades, facilitando la gestión eficiente de órdenes de trabajo en un ERP.

Dentro del campo de la ingeniería industrial, se han desarrollado diversas metodologías para mejorar la productividad y la gestión de recursos, muchas de ellas basadas en principios de automatización y sistemas inteligentes. En este proyecto, se desarrollará un módulo de ERP que empleará algoritmos genéticos para la automatización de la asignación de tareas, permitiendo reducir la intervención manual y mejorar la eficiencia operativa en talleres industriales. A lo largo del estudio, se comparará este enfoque con otras metodologías existentes en la industria, evaluando su desempeño en términos de tiempos de procesamiento, flexibilidad y adaptabilidad a escenarios reales.

Los sistemas ERP (Enterprise Resource Planning) son herramientas integradas que permiten la automatización y gestión de los procesos empresariales esenciales, tales como finanzas, producción, logística y ventas. Un ERP centraliza la información empresarial, optimizando la toma de decisiones y reduciendo la fragmentación de datos, lo que mejora la eficiencia opera-

tiva. Estos sistemas han evolucionado desde los sistemas MRP (Material Requirements Planning) y actualmente constituyen una pieza clave en la digitalización de la industria [3].

3.1.1 Automatización con ERP en talleres industriales

La implementación de ERP en talleres industriales responde a la necesidad de automatizar y estructurar procesos que, de otro modo, se gestionarían de forma manual, lo que puede generar ineficiencias. En los talleres de tecnomecánica, donde se requiere un control riguroso de los repuestos y tiempos de trabajo, un ERP automatizado permite la asignación eficiente de tareas según la disponibilidad de operarios y recursos, reduciendo tiempos de espera y mejorando la productividad.

En un estudio realizado en 2019 [4], se identificó que el 70.4% de las quejas de los clientes en una compañía analizada estaban relacionadas con retrasos en la entrega de órdenes de trabajo, mientras que el 29.6% restante correspondía a problemas de órdenes no confirmadas y reprocesos. Estos problemas, comunes en talleres industriales, pueden ser mitigados mediante un ERP que automatice la distribución de tareas y optimice la administración de recursos, minimizando errores humanos y mejorando la trazabilidad de las órdenes de trabajo.

3.1.2 Algoritmos Genéticos (GA) para la Automatización

La automatización de procesos en entornos industriales ha avanzado con el uso de algoritmos evolutivos, entre los cuales los algoritmos genéticos (GA) han demostrado ser eficaces para resolver problemas de asignación de tareas y planificación de recursos. Estos algoritmos, inspirados en la selección natural y la evolución biológica, trabajan con poblaciones de soluciones potenciales, aplicando operadores como la selección, el cruce (crossover) y la mutación para encontrar soluciones óptimas de manera iterativa [5].

A diferencia de los métodos tradicionales de asignación de tareas, que pueden depender de reglas predefinidas y cálculos deterministas, los algoritmos genéticos ofrecen una solución flexible que se adapta dinámicamente a cambios en el entorno de producción. Gracias a su capacidad de explorar múltiples combinaciones de asignación de tareas y su enfoque probabilístico, los GA

pueden reducir tiempos improductivos y mejorar la distribución del trabajo en talleres industriales.

3.2 Técnicas de Automatización en Ingeniería Industrial

La automatización en ingeniería industrial comprende un conjunto de metodologías, técnicas y herramientas orientadas a optimizar el uso de recursos, reducir desperdicios y mejorar el rendimiento operativo en entornos productivos. Diversos estudios han señalado que la mejora de la eficiencia en talleres y plantas manufactureras depende directamente de la capacidad para programar tareas, asignar recursos y minimizar tiempos improductivos [6, 7]. En los talleres industriales modernos, donde existe alta variabilidad de tareas y heterogeneidad en los tiempos de ejecución, la automatización se convierte en un elemento clave para garantizar un flujo de trabajo continuo y una gestión eficiente de las órdenes de trabajo [8].

Estas técnicas abarcan desde enfoques de mejora continua, como Lean Manufacturing y Six Sigma, hasta métodos formales de secuenciación basados en reglas de prioridad —tales como SPT, FCFS y EDD— que constituyen la base histórica de la programación industrial [9, 10]. Asimismo, la literatura reciente destaca la importancia de combinar estas metodologías con algoritmos avanzados de optimización, dada la complejidad creciente de los sistemas productivos y la naturaleza NP-hard de muchos problemas de scheduling [6, 8].

A continuación se presentan las principales técnicas de automatización utilizadas en la industria para la asignación y programación de tareas, todas ellas relevantes como puntos de comparación frente a métodos evolutivos como los algoritmos genéticos.

3.2.1 Lean Manufacturing y mejora continua

Lean Manufacturing es una filosofía de gestión orientada a la eliminación sistemática de desperdicios (*muda*) y a la optimización del flujo de trabajo mediante la mejora continua. Sus principios, derivados del Sistema de Producción Toyota, se aplican en talleres industriales para reducir tiempos improductivos, minimizar inventarios y mejorar la estabilidad del proceso productivo. La literatura en secuenciación de operaciones y en sistemas de manufactura

destaca que los talleres que adoptan prácticas Lean presentan niveles más estables de procesamiento y menor variabilidad temporal en sus operaciones [7, 6].

En entornos de tecnomecánica y mantenimiento industrial, Lean permite estructurar procesos que tradicionalmente se ejecutan de forma manual o desorganizada, facilitando la estandarización y priorización de tareas. Herramientas como 5S, Value Stream Mapping y Kanban han demostrado ser efectivas para mejorar la trazabilidad de órdenes de trabajo, reducir cuellos de botella y aumentar la utilización de operarios y máquinas [11]. Estas prácticas aportan la base conceptual necesaria para implementar métodos de automatización más avanzados dentro de un ERP, permitiendo que reglas de despacho y algoritmos de optimización operen sobre flujos de trabajo más consistentes.

3.2.2 Six Sigma y reducción de variabilidad

Six Sigma es una metodología orientada a reducir la variabilidad de los procesos mediante técnicas estadísticas avanzadas y un enfoque basado en datos. Su ciclo DMAIC permite analizar de manera estructurada las causas de ineficiencias y establecer mejoras que impactan directamente la estabilidad del sistema productivo. La investigación en sistemas de manufactura reporta que Six Sigma mejora la precisión en los tiempos de proceso y disminuye la ocurrencia de operaciones re-trabajadas o reprocesos [6].

En talleres de mantenimiento automotriz o metalmecánica, Six Sigma facilita la estandarización de tiempos de reparación, la identificación de cuellos de botella y la reducción de variaciones entre operarios, contribuyendo a un entorno más predecible para la programación de tareas. La reducción de variabilidad es fundamental para que los métodos de scheduling —tanto heurísticos como metaheurísticos— puedan operar bajo condiciones de mayor estabilidad y precisión [8, 9].

3.2.3 Investigación de Operaciones aplicada al Scheduling

La Investigación de Operaciones (IO) ha desarrollado modelos matemáticos para resolver problemas de asignación, secuenciación y optimización de recursos. En el ámbito de la producción industrial, estos modelos incluyen:

- Programación Lineal Entera Mixta (MILP)
- Branch and Bound
- Programación Dinámica
- Modelos deterministas de Flow Shop, Job Shop y Flexible Job Shop

Estos problemas son ampliamente conocidos por su complejidad computacional, siendo Job Shop y Flexible Job Shop NP-hard [6, 7]. Si bien los modelos exactos permiten obtener soluciones óptimas, en la práctica su uso se limita a problemas de pequeña escala debido al crecimiento exponencial del espacio de búsqueda. Investigaciones recientes han demostrado que, incluso con técnicas avanzadas como Constraint Programming, resolver problemas de scheduling con múltiples restricciones sigue siendo un reto significativo para sistemas reales [12].

Por esta razón, en escenarios industriales complejos se emplean heurísticas, reglas de despacho y metaheurísticas que permiten obtener soluciones de buena calidad en tiempos computacionales reducidos [9, 10].

3.2.4 Reglas de prioridad (Dispatching Rules)

Las reglas de prioridad constituyen uno de los métodos clásicos más utilizados para la programación de tareas en entornos industriales debido a su simplicidad, bajo coste computacional y fácil implementación. Estas reglas se basan en atributos específicos de las tareas, como tiempo de procesamiento, fecha de entrega o urgencia.

Las reglas más representativas incluyen:

- **SPT (Shortest Processing Time)**

Prioriza las tareas más cortas, reduciendo el tiempo promedio de flujo y el tiempo total en el sistema. Es una técnica particularmente eficiente en sistemas sin restricciones complejas [6]. Esta regla se utiliza como base comparativa en esta investigación.

- **FCFS (First Come, First Served)** Procesa tareas en el orden en que llegan. Aunque sencilla, puede generar tiempos improductivos o cargas desbalanceadas [7].

- **EDD (Earliest Due Date)** Minimiza el retraso (tardiness) priorizando tareas con fechas de entrega más próximas. Es una regla ampliamente usada en la industria gráfica y manufactura ligera [9].
- **LPT (Longest Processing Time)** Favorece las tareas más largas y es útil en escenarios donde se busca balancear carga entre máquinas paralelas.
- **Reglas híbridas** Combinan múltiples criterios como tiempo, urgencia y vencimiento. Son más flexibles y representan la transición entre heurísticas clásicas y metaheurísticas [10].

Estas reglas son consideradas baseline industrial y sirven como punto de referencia para evaluar técnicas más avanzadas como algoritmos genéticos o algoritmos híbridos [9, 10].

3.2.5 Métodos heurísticos clásicos

Las heurísticas permiten obtener soluciones aproximadas para problemas de scheduling de manera rápida. Aunque no garantizan optimalidad, son valiosas en entornos industriales por su eficiencia computacional.

Entre las más destacadas se encuentran:

- Heurísticas de cuello de botella
- Algoritmos constructivos como NEH (Flow Shop) o G&T (Job Shop)
- List Scheduling
- Heurísticas parametrizadas por prioridad

Estudios en Flow Shop y Flexible Job Shop señalan que estas heurísticas ofrecen buen desempeño cuando el entorno productivo es estable y presenta pocas restricciones [6, 7]. Sin embargo, su desempeño disminuye considerablemente cuando existen múltiples dependencias, precedencias o recursos limitados—como es el caso en talleres industriales reales—, por lo que requieren ser complementadas con metaheurísticas [9].

3.2.6 Metaheurísticas aplicadas al scheduling

Debido a la complejidad de los problemas industriales de programación de tareas, especialmente aquellos con múltiples máquinas, precedencias y restricciones, las metaheurísticas se han convertido en herramientas fundamentales para obtener soluciones de alta calidad.

Las técnicas más utilizadas incluyen:

- Recocido Simulado (SA)
- Búsqueda Tabú (TS)
- Algoritmos Genéticos (GA)
- PSO (Particle Swarm Optimization)
- Algoritmos híbridos (GA + SA, GA + TS)

La literatura presenta numerosos casos donde los GA y los métodos híbridos superan significativamente a las heurísticas tradicionales y reglas de prioridad [9, 6]. Del mismo modo, revisiones recientes sobre programación en Industria 4.0 y 5.0 destacan el papel de las metaheurísticas en sistemas productivos dinámicos y altamente automatizados [8].

3.2.7 Métodos deterministas y exactos

Aunque su aplicabilidad es limitada en escenarios complejos, los métodos exactos cumplen un rol fundamental como referencia teórica para evaluar heurísticas y metaheurísticas.

Estos métodos incluyen:

- Branch & Bound
- Branch & Cut
- Constraint Programming (CP)
- Programación Lineal y Entera

Investigaciones recientes en CP demuestran que si bien estas técnicas logran acotar soluciones y obtener resultados cercanos al óptimo en algunos casos, su escalabilidad aún es limitada en problemas como FJSSP y JSSP [12]. Por ello, suelen emplearse solo para casos pequeños o como benchmark teórico.

3.3 Antecedentes

La programación de tareas en entornos industriales ha sido un campo de estudio ampliamente abordado en la literatura debido a la complejidad inherente de problemas como Flow Shop, Job Shop y Flexible Job Shop, todos ellos catalogados como NP-hard [6, 7]. Esta complejidad ha motivado el desarrollo de metodologías basadas en heurísticas, reglas de despacho y metaheurísticas avanzadas para obtener soluciones eficientes dentro de límites computacionales razonables. En este contexto, los algoritmos genéticos (AG) han demostrado un rendimiento destacado en la optimización de tareas, especialmente en escenarios donde múltiples restricciones interactúan entre sí.

Uno de los trabajos más relevantes es el de Delgado et al. [13], quienes propusieron un algoritmo genético para la programación de tareas en una celda de manufactura y compararon su desempeño con métodos heurísticos tradicionales. Sus resultados mostraron que los AG pueden reducir tiempos improductivos y mejorar la utilización de recursos, destacando su capacidad para explorar soluciones que las reglas de prioridad no alcanzan debido a su naturaleza determinista.

De manera complementaria, Meisel y Prado [9] desarrollaron un algoritmo genético híbrido que incorpora enfriamiento simulado, demostrando que las metaheurísticas híbridas pueden ofrecer soluciones más estables y de mayor calidad en problemas de tipo Job Shop. Este estudio respalda la idea de que los AG son especialmente adecuados para problemas con múltiples restricciones, como precedencias, máquinas en paralelo y tiempos variables de procesamiento.

En el ámbito de la automatización industrial desde la perspectiva de Industria 4.0, Zhang et al. [8] presentan un análisis del estado del arte de algoritmos evolutivos aplicados a la programación en sistemas inteligentes. Su investigación concluye que los AG, junto con técnicas híbridas de optimización, son herramientas clave para la toma de decisiones en entornos altamente dinámicos y automatizados. Esta tendencia refuerza la pertinencia del uso de AG como enfoque moderno para la gestión de recursos en talleres industriales.

En cuanto a la asignación de tareas en problemas de tipo Task Assignment Problem (TAP), Savić et al. [14] demostraron que los AG pueden encontrar soluciones óptimas o cercanas al óptimo en espacios de búsqueda complejos, superando métodos deterministas y heurísticos en términos de tiempo de ejecución y calidad de resultados. De forma similar, Wang [15] aplicó algoritmos genéticos al diseño automático de maquinaria, mostrando

mejoras significativas frente a métodos tradicionales en precisión y tiempos de procesamiento.

Por otra parte, investigaciones sobre heurísticas industriales, como las reglas de despacho SPT, EDD y FCFS, han demostrado ser métodos simples y eficientes para problemas básicos de secuenciación, pero con limitaciones marcadas en problemas con múltiples restricciones o estructuras complejas de precedencia [10, 6]. Esta brecha entre simplicidad y capacidad de adaptación es precisamente lo que motiva la comparación entre SPT y algoritmos evolutivos en el presente estudio.

En conjunto, estos antecedentes evidencian que los algoritmos genéticos han sido utilizados con éxito en diversos dominios de la optimización industrial, mientras que las heurísticas tradicionales siguen siendo herramientas fundamentales como métodos comparativos o de referencia. En el caso particular de un taller industrial basado en un sistema ERP, la literatura existente es limitada. Por ello, el presente proyecto aporta un enfoque novedoso al integrar un algoritmo genético dentro de un entorno simulado que replica el flujo real de un taller automotriz, comparándolo directamente con una heurística industrialmente aceptada como SPT. Esta comparación permite evaluar el potencial de los AG para mejorar la asignación de tareas y la eficiencia operativa en un contexto aplicado.

Chapter 4

Formalización del problema

El presente capítulo describe la estructura formal del problema de programación diaria del taller industrial, incluyendo la caracterización del flujo operativo, la definición matemática de los elementos que componen el sistema y la modelación del comportamiento del taller bajo sus restricciones reales. Esta formalización constituye la base para el desarrollo posterior del algoritmo genético y el método SPT, presentados en los capítulos siguientes.

4.1 Estudio del flujo de trabajo del taller industrial

El taller de reparación de motores opera bajo un flujo secuencial condicionado por restricciones de precedencia, disponibilidad de repuestos, habilidades del personal e interacción entre tareas dentro de una misma orden de trabajo. Cada día se recibe un conjunto de órdenes de trabajo que agrupan tareas mecánicas con distintos requerimientos técnicos, y el objetivo operativo es completar la mayor cantidad posible de dichas tareas dentro de la jornada laboral.

4.1.1 Tipos de tareas

Sea $T = \{1, \dots, q\}$ el conjunto de tipos de tareas que el taller está en capacidad de ejecutar. Cada tipo de tarea representa una operación específica dentro del proceso de reparación, cuya duración base está dada por una función:

$$p : T \rightarrow \mathbb{N}$$

que asigna a cada tipo $t \in T$ su duración en minutos.
Las tareas concretas del día se representan mediante:

$$T_d = \{1, \dots, n\},$$

donde cada tarea $i \in T_d$ posee los atributos:

- $ot(i)$: orden de trabajo a la que pertenece;
- $tipo(i)$: tipo de tarea según T ;
- $p(tipo(i))$: duración efectiva.

4.1.2 Operarios y recursos disponibles

Sea $O = \{1, \dots, r\}$ el conjunto de operarios disponibles en el taller. Cada tarea requiere habilidades específicas, modeladas mediante:

$$E(t) \subseteq O, \quad \forall t \in T,$$

donde $E(t)$ es el conjunto de operarios aptos para ejecutar tareas del tipo t . La aptitud del operario es una restricción estricta: una tarea no puede ser programada por un operario fuera de $E(tipo(i))$.

4.1.3 Reglas industriales de asignación

El taller opera bajo restricciones naturales del proceso mecánico:

- **Precedencias intrínsecas:** ciertas tareas deben completarse antes de que otras puedan iniciar. Modelado mediante:

$$P(t) \subseteq T,$$

que representa los tipos de tarea que deben preceder al tipo t .

- **Precedencias por orden de trabajo:** sólo son relevantes aquellas precedencias que ocurren dentro de la misma orden de trabajo.

- **Disponibilidad de repuestos:** cada orden de trabajo ot tiene asociado un vector binario:

$$R_{ot} = (r_1, r_2, \dots), \quad r_j \in \{0, 1\},$$

donde $r_j = 1$ indica que el repuesto necesario para cierto tipo de tarea está disponible.

- **Capacidad temporal:** cada operario posee un máximo de 8 horas de trabajo:

$$H = 480 \text{ minutos.}$$

4.1.4 Análisis del proceso actual y puntos críticos

El proceso presenta dificultades estructurales:

- Los operarios poseen habilidades heterogéneas.
- Las órdenes contienen dependencias internas que condicionan el flujo.
- Los repuestos no siempre están disponibles.
- El tiempo límite de jornada restringe la cantidad de tareas ejecutables.
- Tareas pertenecientes a una misma orden no pueden solaparse.

El resultado es un entorno altamente restrictivo donde la programación manual es compleja y propensa a tiempos improductivos.

4.1.5 Flujo general del proceso

Operativamente, el taller funciona bajo este flujo conceptual:

1. Llegan varias órdenes de trabajo, cada una con un conjunto de tareas.
2. Cada tarea requiere un operario apto y, en algunos casos, un repuesto.
3. Algunas tareas dependen de otras dentro de la misma orden.
4. Los operarios ejecutan las tareas secuencialmente en una jornada limitada.
5. El objetivo es completar la mayor cantidad posible de tareas.

Este flujo será simulado formalmente en la evaluación de soluciones.

4.2 Diseño del modelo de datos para la simulación

4.2.1 Conjuntos y parámetros del sistema

El problema se formaliza mediante los siguientes conjuntos:

$$\begin{aligned} OT &= \{1, \dots, m\} && \text{Órdenes de trabajo,} \\ T_d &= \{1, \dots, n\} && \text{Tareas del día,} \\ O &= \{1, \dots, r\} && \text{Operarios,} \\ T &= \{1, \dots, q\} && \text{Tipos de tarea.} \end{aligned}$$

Parámetros principales:

$$\begin{aligned} p(t) &&& \text{Duración del tipo de tarea } t, \\ E(t) \subseteq O &&& \text{Operarios aptos,} \\ P(t) \subseteq T &&& \text{Precedencias por tipo,} \\ R_{ot} &&& \text{Vector de disponibilidad de repuestos para la OT,} \\ H = 480 &&& \text{Horizonte máximo diario.} \end{aligned}$$

4.2.2 Variables del modelo

Durante la simulación se manejan variables que representan el estado del taller:

$$\begin{aligned} tpo[o] &: \text{tiempo utilizado por el operario } o, \\ comp[ot] &: \text{tipos de tareas ya completadas en la OT,} \\ occ[ot] &: \text{intervalos ocupados por la OT.} \end{aligned}$$

4.2.3 Representación de operarios, tareas y repuestos

- Las tareas se representan por su índice i y atributos: tipo, orden y duración.
- Un operario sólo puede ejecutar tareas cuyos tipos estén en $E(t)$.
- Los repuestos se representan mediante el vector binario R_{ot} .

4.2.4 Tiempos de operación y estructura temporal

El tiempo se representa en minutos dentro del intervalo $[0, H]$. Una tarea i ejecutada por un operario o genera un intervalo:

$$[s_i, f_i) = [tpo[o], tpo[o] + p(tipo(i))).$$

4.2.5 Restricciones formales del taller

Una tarea i puede ejecutarse si y sólo si:

- (1) $o \in E(tipo(i))$ Aptitud del operario,
- (2) $R_{ot(i)}$ provee repuesto disponible Repuesto disponible,
- (3) $P(tipo(i)) \cap T_{ot(i)} \subseteq comp[ot(i)]$ Precedencias cumplidas,
- (4) $f_i \leq H$ No excede jornada,
- (5) $[s_i, f_i) \cap occ[ot(i)] = \emptyset$ No solapa con tareas de la misma OT.

4.3 Construcción del generador de instancias

4.3.1 Parámetros de la simulación y alcance

Cada día se genera una instancia compuesta por:

- Un conjunto de órdenes.
- Un conjunto de tareas concretas.
- Habilidades del personal.
- Duraciones de tareas.
- Precedencias.
- Repuestos disponibles.

4.3.2 Modelo de aleatoriedad y distribución de tiempos

El generador recibe:

- El número de órdenes,
- El número de tareas por orden,
- Su distribución temporal (según $p(t)$),
- Disponibilidad de repuestos,
- Habilidades por tipo.

4.3.3 Procedimiento de creación de escenarios

El proceso consiste en:

1. Seleccionar órdenes y sus tareas.
2. Asignar tipos y duraciones.
3. Generar disponibilidad de repuestos.
4. Asignar operarios aptos por tipo.
5. Construir la instancia final (OT, T_d, O) .

4.3.4 Validación del modelo simulado con expertos

Los parámetros fueron validados con personal del taller, asegurando que:

- Las duraciones son realistas.
- Las precedencias corresponden al flujo mecánico real.
- Las habilidades reflejan la estructura del personal.
- El horizonte de 8 horas es consistente con el turno laboral.

4.3.5 Pseudocódigo del simulador operativo

El corazón de la simulación consiste en determinar si una asignación propuesta es válida. El pseudocódigo siguiente refleja el comportamiento operativo del taller:

Algorithm 1: Simulación operativa de programación de tareas

```

Inicializar estructuras:  $tpo[o] \leftarrow 0$ ,  $comp[ot] \leftarrow \emptyset$ ,  $occ[ot] \leftarrow \emptyset$ ;
foreach operario  $o \in O$  do
    Obtener conjunto de tareas asignadas  $T_o$ ;
    Ordenar  $T_o$  según prioridad descendente;
    foreach tarea  $i \in T_o$  do
        Verificar aptitud:  $o \in E(tipo(i))$ ;
        Verificar repuesto disponible;
        Verificar precedencias cumplidas en  $comp[ot(i)]$ ;
        Calcular intervalo  $[s_i, f_i] = [tpo[o], tpo[o] + p(tipo(i))]$ ;
        if  $f_i > H$  then
            | rechazar tarea; continuar
        end
        if  $[s_i, f_i]$  solapa con algún intervalo en  $occ[ot(i)]$  then
            | rechazar tarea; continuar
        end
        Aceptar tarea: actualizar  $tpo[o]$ ,  $comp$ ,  $occ$ ;
    end
end

```

4.4 Conjunto final de escenarios utilizados en la comparación

4.4.1 Número y estructura de las instancias

Para la fase experimental se consideraron múltiples instancias generadas bajo diferentes configuraciones de:

- número de órdenes,
- número de tareas,
- complejidad de precedencias,

- disponibilidad de recursos.

4.4.2 Variabilidad incorporada

Las instancias presentan variabilidad en:

- tamaño del conjunto de tareas,
- carga operativa,
- composición de órdenes,
- mezcla de repuestos disponibles.

4.4.3 Justificación de los casos de estudio

Estas instancias permiten evaluar el desempeño del método SPT y del algoritmo genético en condiciones diversas, representando escenarios realistas del taller.

Chapter 5

Desarrollo de la Solución

5.1 Modelado del Problema como Problema de Optimización

El problema se formula como un problema de asignación y secuenciación de tareas sujeto a múltiples restricciones operativas. El objetivo general consiste en maximizar el número de tareas programadas dentro de un horizonte diario de 8 horas por operario, garantizando la factibilidad respecto a precedencias, disponibilidad de repuestos y cualificación del personal.

5.1.1 Variables

Variables de decisión:

- y_i : operario asignado a la tarea i , donde $y_i \in E(\text{tipo}(i))$.
- $\pi_i \in [0, 1]$: prioridad asignada a la tarea i para determinar su orden de intento de programación.

Variables auxiliares utilizadas en la simulación:

- $tpo[o]$: tiempo total utilizado por el operario o .
- $comp[ot]$: conjunto de tareas completadas dentro de la orden de trabajo ot .
- $occ[ot]$: intervalos ocupados en la orden de trabajo ot .

5.1.2 Restricciones

- **Aptitud del operario:** $y_i \in E(\text{tipo}(i))$.
- **Disponibilidad de repuesto:** Solo puede programarse una tarea si el repuesto asociado a su orden de trabajo está disponible.
- **Precedencias internas de la misma OT:**

$$\forall t' \in (\mathcal{P}(\text{tipo}(i)) \cap \text{OT}(i)) : t' \in \text{comp}[\text{ot}(i)]$$

- **Horizonte máximo diario:** $f_i \leq H$.
- **No solapamiento dentro de la misma OT:**

$$\neg(s_i < f' \wedge f_i > s'), \quad \forall [s', f'] \in \text{occ}[\text{ot}(i)]$$

5.1.3 Función Objetivo

La función objetivo maximiza el número de tareas programadas y penaliza violaciones a las restricciones:

$$\text{fitness} = 100N_{\text{exec}} - 10P_{\text{prec}} - 10P_{\text{rep}} - 15P_{\text{apt}} - 12P_{\text{ot}} - 0.1E_{\text{hor}} - 0.5\sigma - 0.1C_{\text{max}}$$

donde los términos representan: N_{exec} tareas ejecutadas, P_{prec} violaciones de precedencia, P_{rep} faltas de repuestos, P_{apt} asignaciones a operarios no aptos, P_{ot} solapamientos en la misma orden, E_{hor} excede del horizonte, σ desviación estándar (balance de carga), C_{max} makespan.

5.2 Diseño del Algoritmo Genético

El algoritmo genético se diseñó para explorar combinaciones de asignación y secuenciación que respeten la estructura operativa del taller. Cada individuo representa un cronograma potencial que es evaluado mediante una simulación determinista.

5.2.1 Representación

Cada individuo se define como un vector de $2n$ dimensiones:

$$[y_1, \dots, y_n] \parallel [\pi_1, \dots, \pi_n]$$

- Primeros n genes: operario asignado, restringido al conjunto $E(\text{tipo}(i))$.
- Últimos n genes: prioridades en $[0, 1]$.

5.2.2 Selección

Se empleó selección por **ranking**, adecuada para entornos donde la distribución de aptitud puede ser muy desigual debido a penalizaciones fuertes.

5.2.3 Cruce

Se utilizó cruce de tipo **single__point**, apropiado debido a que el cromosoma posee dos mitades homogéneas: asignación y prioridad.

5.2.4 Mutación

Mutación aleatoria sobre el **15%** de los genes:

- Para asignaciones: se elige aleatoriamente un nuevo operario dentro de $E(\text{tipo}(i))$.
- Para prioridades: se asigna un valor continuo uniforme en $[0, 1]$.

5.2.5 Parámetros

- Generaciones: 250
- Población: 100 individuos
- Padres por generación: 10
- Padres preservados: 5
- Semilla: 42 (reproducibilidad)

Evaluación del Individuo

La simulación determina:

- tareas ejecutadas,
- tareas rechazadas por precedencias, repuestos, aptitud o solapamiento,
- balance de carga entre operarios,
- makespan del sistema.

5.3 Implementación del Método SPT

Texto pendiente.

5.4 Integración con el Entorno Simulado

Texto pendiente.

5.5 Arquitectura General del Sistema Desarrollado

Texto pendiente.

Chapter 6

Implementación

Este capítulo describe la implementación del sistema desarrollado para la programación diaria de tareas en un taller industrial. Se detalla el entorno de desarrollo utilizado, la arquitectura del software, la implementación del algoritmo genético y del método SPT, así como el procedimiento empleado para ejecutar las simulaciones que permiten comparar ambos métodos. La descripción presentada no incluye fragmentos de código fuente, sino explicaciones conceptuales y pseudocódigo cuando es pertinente, siguiendo las recomendaciones establecidas por la dirección del trabajo.

6.1 Entorno de desarrollo

El sistema fue implementado en el lenguaje de programación Python, debido a su flexibilidad, amplia disponibilidad de librerías para optimización y manejo de datos, y su compatibilidad con métodos heurísticos y evolutivos. Para garantizar portabilidad y consistencia, se empleó un entorno virtual administrado mediante **venv**.

Las principales dependencias utilizadas fueron:

- **NumPy**: manejo eficiente de arreglos y operaciones matemáticas.
- **Pandas**: construcción de estructuras tabulares para generar y almacenar instancias.
- **PyGAD**: librería empleada para la implementación del algoritmo genético.

- **Random:** generación de valores pseudoaleatorios para la creación de instancias.

El archivo `requirements.txt` incluye las versiones exactas utilizadas, permitiendo reproducir las condiciones de ejecución en cualquier sistema.

6.2 Diseño del software

El proyecto se estructuró siguiendo una arquitectura modular, organizada en tres componentes principales: generación de instancias, algoritmos de programación (AG y SPT) y simulación. Esto permite separar claramente la lógica del modelo del taller, los métodos de asignación y el procedimiento experimental.

6.2.1 Arquitectura general del sistema

A continuación se presenta la organización del software:

- **config/:** contiene la configuración del taller y el generador de instancias.
- **ag/:** módulo que implementa el algoritmo genético.
- **spt/:** módulo con la implementación del método SPT.
- **simulador.py:** orquesta la ejecución de instancias, aplicar ambos algoritmos y almacenar los resultados.

Cada componente se comunica únicamente mediante estructuras de datos bien definidas, lo que facilita la extensibilidad y la validación del sistema.

6.2.2 Flujo general del software

El funcionamiento completo del sistema puede resumirse como:

1. **Generación de instancias:** se construyen escenarios según la configuración del taller.
2. **Ejecución de SPT y AG:** cada instancia se evalúa mediante ambos métodos.

3. **Simulación operativa:** se usa la simulación formalizada en el Capítulo 4 para determinar las tareas aceptadas, rechazadas y métricas de desempeño.
4. **Consolidación de resultados:** se almacenan métricas en archivos CSV para su análisis posterior.

Este pipeline es consistente con el objetivo principal de la tesis: comparar el desempeño del algoritmo genético frente a un método clásico de ingeniería industrial.

6.3 Implementación del algoritmo genético

El módulo `ag/ag.py` implementa el algoritmo genético utilizando la librería PyGAD. El enfoque se basa en la representación dual del individuo, donde cada solución codifica simultáneamente la asignación de operarios y la prioridad de ejecución de cada tarea.

6.3.1 Representación del individuo

Dado un conjunto de tareas del día con tamaño n , se construye un cromosoma de longitud $2n$:

$$\text{individuo} = [o_1, \dots, o_n, w_1, \dots, w_n]$$

donde:

- o_i es el operario seleccionado para la tarea i .
- w_i es un valor que representa la prioridad relativa de la tarea.

Esta representación permite modular tanto la asignación como la secuencia interna de ejecución.

6.3.2 Generación del espacio de búsqueda

El archivo `taller_config.py` define, para cada tipo de tarea, qué operarios son aptos para ejecutarla. Esta información se utiliza para construir dinámicamente el *gene space* del AG, restringiendo valores inválidos y reduciendo el espacio de búsqueda.

6.3.3 Función de aptitud

La función de aptitud está implementada de manera que evalúa cada individuo llamando al simulador operativo descrito en el Capítulo 4. El resultado final se obtiene mediante una métrica compuesta que penaliza:

- Tareas rechazadas.
- Precedencias incumplidas.
- Exceso de carga.

Y recompensa:

- Cantidad de tareas ejecutadas.
- Balance de carga entre operarios.

El pseudocódigo general de la evaluación es:

Algorithm 2: Evaluación de un individuo mediante simulación operativa

Obtener asignación de operarios y prioridades desde el individuo;
 Construir ordenamiento de tareas según prioridades;
 Aplicar simulación operativa;
 Calcular métricas: ejecutadas, rechazadas, makespan, carga total, etc.;
 Combinar métricas en una aptitud final;

6.3.4 Integración con PyGAD

El AG se ejecuta definiendo:

- tamaño de población,
- número de generaciones,
- probabilidad de cruce,
- probabilidad de mutación.

PyGAD administra el proceso evolutivo, mientras que la evaluación real se realiza con el simulador del taller.

6.4 Implementación del método SPT

El módulo `spt/spt.py` implementa la heurística Shortest Processing Time (SPT), adaptada al contexto del taller. La versión utilizada en esta tesis mantiene el espíritu del método clásico, pero incorpora restricciones reales del taller, como habilidades de operarios, repuestos y precedencias.

6.4.1 Ordenamiento de tareas

El método ordena las tareas según la duración:

$$\text{orden SPT : } p(\text{tipo}(i_1)) \leq p(\text{tipo}(i_2)) \leq \dots$$

Este orden se ajusta automáticamente según precedencias y recursos disponibles.

6.4.2 Asignación de operarios y validación

Para cada tarea ordenada, el método:

1. identifica operarios aptos,
2. selecciona aquel con menor carga acumulada,
3. verifica disponibilidad de repuestos,
4. evalúa posibles solapamientos dentro de la misma OT.

Si la tarea no puede ejecutarse bajo las restricciones del taller, se marca como rechazada.

6.5 Ejecución de simulaciones

El archivo `simulador.py` ejecuta el experimento completo. Para cada instancia generada, se aplican consecutivamente el método SPT y el algoritmo genético, almacenando métricas clave que permitirán una comparación justa.

6.5.1 Generación de conjuntos de instancias

Las instancias se generan con el módulo `generador_instancias.py`, que permite configurar:

- número mínimo y máximo de órdenes,
- número total de tareas,
- distribución de tipos,
- disponibilidad de repuestos.

6.5.2 Ejecución conjunta de SPT y AG

Para cada instancia:

1. se ejecuta SPT y se registra su desempeño,
2. se ejecuta el AG y se obtiene el mejor individuo,
3. ambos resultados se evalúan con el simulador,
4. se registran métricas comparables.

6.5.3 Consolidación de resultados

Los datos generados por cada ejecución se almacenan en un archivo CSV, que posteriormente es utilizado en el Capítulo 7 para el análisis cuantitativo.

6.5.4 Reproducibilidad

Para garantizar repetibilidad, se fijan semillas aleatorias y se documentan los parámetros utilizados en cada corrida experimental.

6.5.5 Evaluación del Operador de Cruce

Con el fin de determinar el operador de cruce más adecuado para el algoritmo genético, se realizó un experimento comparativo empleando los dos métodos soportados por la librería PyGAD que preservan parcialmente la estructura del individuo: *single_point* y *two_points*. Ambos operadores fueron evaluados bajo las mismas condiciones iniciales del algoritmo, utilizando la configuración base descrita en la Sección [acá va la ref]. Cada ejecución consistió en la generación de veinte instancias independientes.

Dado que el objetivo del algoritmo genético es optimizar la programación en condiciones realistas del taller, el experimento se llevó a cabo exclusivamente sobre el horizonte operativo de 480 minutos. Este escenario corresponde a una jornada laboral completa y ofrece suficiente espacio temporal para que el AG explore secuencias complejas, revelando diferencias significativas entre operadores evolutivos. Los horizontes reducidos generan comportamientos artificialmente similares entre configuraciones, motivo por el cual no se consideran en esta etapa de calibración.

Los resultados promedio de las métricas relevantes para el AG se presentan en la Tabla [ACÁ VA LA REF].

Table 6.1: Resultados promedio del AG para cada operador de cruce (480 minutos).

Operador de cruce	Tareas ejecutadas	Tareas rechazadas	Makespan	Carga total
<i>single_point</i>	26.20	17.55	212.60	613.85
<i>two_points</i>	24.55	14.85	206.10	568.80

Los resultados muestran diferencias claras entre los dos operadores. El operador *single_point* ejecuta, en promedio, 1.65 tareas adicionales respecto a *two_points*, lo cual es significativo dado el tamaño del horizonte y las restricciones del taller. Asimismo, alcanza una mayor carga total, indicando una mejor utilización del tiempo disponible de los operarios. Aunque *two_points* obtiene un makespan ligeramente menor, la diferencia no compensa la pérdida en tareas ejecutadas, métrica prioritaria en el contexto del taller de rectificado.

En síntesis, el operador *single_point* presenta un comportamiento más robusto y consistente en escenarios amplios. Por este motivo, se seleccionó como operador de cruce para los siguientes experimentos del proceso de calibración del algoritmo genético.

6.5.6 Evaluación del Número de Generaciones

Tras seleccionar el operador de cruce *single_point*, el siguiente paso en la calibración del algoritmo genético consistió en determinar un número adecuado de generaciones. Este parámetro controla la profundidad de la búsqueda evolutiva y afecta tanto la calidad de las soluciones como el costo computacional del proceso.

Siguiendo recomendaciones comunes en la literatura sobre algoritmos genéticos, se evaluaron tres niveles de profundidad evolutiva: 300, 800 y 1300 generaciones. Estos valores representan una escala progresiva de exploración del espacio de búsqueda (baja, media y alta), y permiten estudiar la convergencia del algoritmo sin incurrir en tiempos de ejecución excesivos. Todas las ejecuciones conservaron la misma configuración base presentada en la Sección [FIGURA ACÁ].

El experimento se llevó a cabo sobre veinte instancias independientes bajo un horizonte de 480 minutos, correspondiente a una jornada realista del taller. Los resultados promedio obtenidos se resumen en la Tabla 6.2.

Table 6.2: Resultados promedio del AG para distintos números de generaciones (480 minutos).

Generaciones	Tareas ejecutadas	Tareas rechazadas	Makespan	Carga total
300	26.60	13.25	208.55	620.85
800	25.25	16.55	219.95	592.35
1300	24.35	12.80	204.70	563.65

Los resultados muestran que el mejor desempeño global se alcanza con 300 generaciones, obteniendo el mayor número promedio de tareas ejecutadas (26.60) y la mayor carga total (620.85). A medida que se incrementa el número de generaciones, el algoritmo no presenta mejoras sustanciales y, por el contrario, tiende a obtener cronogramas con menor número de tareas completadas. Este comportamiento sugiere que el AG converge rápidamente en este problema, y que extender el proceso evolutivo más allá de 300 generaciones no aporta beneficios significativos en términos de calidad de solución.

Considerando tanto el desempeño observado como la eficiencia computacional, se seleccionó **300 generaciones** como valor óptimo para las siguientes etapas del proceso de calibración.

6.5.7 Evaluación de la Probabilidad de Mutación

El último parámetro evaluado en el proceso de calibración del algoritmo genético corresponde a la probabilidad de mutación. Este parámetro controla el grado de exploración del espacio de búsqueda mediante modificaciones aleatorias en los genes del individuo. En términos prácticos, una mutación demasiado baja puede llevar a una convergencia prematura, mientras que una mutación demasiado alta puede destruir estructuras útiles adquiridas durante el proceso evolutivo.

Siguiendo prácticas habituales en la literatura, se evaluaron tres niveles representativos de intensidad de mutación: 5%, 15% y 25%. Estos valores permiten analizar la sensibilidad del algoritmo a distintos grados de exploración aleatoria. Todas las ejecuciones se realizaron bajo la configuración base detallada en la Sección [FIGURA ACA], con el operador de cruce previamente seleccionado y un horizonte de 480 minutos.

Los resultados promedio obtenidos a partir de veinte instancias independientes se presentan en la Tabla 6.3.

Table 6.3: Resultados promedio del AG para diferentes probabilidades de mutación (480 minutos).

Probabilidad de mutación	Tareas ejecutadas	Tareas rechazadas	Makespan	Carga total
5%	19.85	14.85	172.05	454.50
15%	25.00	14.80	216.60	582.05
25%	24.20	15.00	201.85	554.50

Los resultados muestran diferencias claras entre los distintos niveles de mutación evaluados. Una mutación baja (5%) conduce a un desempeño significativamente inferior, evidenciando una fuerte convergencia prematura que limita la capacidad del algoritmo para explorar alternativas factibles dentro del horizonte disponible.

El valor intermedio (15%) proporciona el mejor rendimiento global, alcanzando tanto la mayor cantidad de tareas ejecutadas como la mayor carga total. Esto sugiere un buen equilibrio entre exploración y explotación del espacio de búsqueda: la mutación es lo suficientemente alta para evitar estancamiento, pero no tan elevada como para destruir las estructuras útiles generadas por el operador de cruce.

Finalmente, un nivel más alto de mutación (25%) muestra un rendimiento ligeramente inferior al valor intermedio. Aunque mejora el makespan en

comparación con el caso de 15%, su capacidad de programación se reduce, indicando que una mayor aleatoriedad comienza a afectar la estabilidad del proceso evolutivo.

A partir de estos resultados, se selecciona una probabilidad de mutación del **15%** como el valor óptimo para la configuración final del algoritmo genético.

6.6 Configuración Final del AG

A partir del proceso de calibración presentado en las subsecciones anteriores —donde se evaluaron de forma independiente el operador de cruce, el número de generaciones y la probabilidad de mutación— se obtuvo una configuración final del algoritmo genético que equilibra de manera adecuada la calidad de las soluciones y el costo computacional. Esta configuración fue utilizada en todas las comparaciones realizadas posteriormente contra el método SPT en el Capítulo 7. En síntesis, la calibración determinó que:

- El operador de cruce *single_point* ofrece el mejor desempeño en un horizonte amplio de 480 minutos, superando consistentemente a *two_points*.
- Un número de **300 generaciones** es suficiente para que el algoritmo converja hacia soluciones de alta calidad, mientras que valores mayores no aportan mejoras significativas y pueden incluso degradar el rendimiento.
- Una probabilidad de mutación del **15%** logra el mejor equilibrio entre exploración y explotación del espacio de búsqueda, evitando tanto la convergencia prematura (como sucede con 5%) como la pérdida de estabilidad evolutiva (observada con 25%).

Con base en estos resultados, la configuración final del algoritmo genético utilizada en las simulaciones comparativas es la siguiente:

Esta configuración proporciona un desempeño robusto en términos de tareas ejecutadas, carga total y estabilidad del proceso evolutivo. Además, se mantiene dentro de límites razonables de tiempo de ejecución, lo que facilita su aplicación práctica en un taller industrial. Los experimentos del capítulo siguiente emplean exclusivamente esta configuración, garantizando que la comparación frente al método SPT se realice bajo condiciones justas y reproducibles.

Table 6.4: Configuración final seleccionada para el algoritmo genético.

Parámetro	Valor seleccionado
Operador de cruce	<i>single_point</i>
Número de generaciones	300
Tamaño de población	100
Método de selección	<i>rank</i>
Padres por generación	10
Padres preservados	5
Probabilidad de mutación	15%
Semilla aleatoria	42

Chapter 7

Analisis de Resultados

7.1 Métricas utilizadas

7.1.1 Tareas ejecutadas

7.1.2 Tareas rechazadas

7.1.3 Sobrecarga (carga total)

7.1.4 Balance de carga (desviación estándar)

7.1.5 Makespan

7.2 Comparación AG vs SPT

7.2.1 Descripción general de los resultados

7.2.2 Análisis de distribución

7.2.3 Tareas ejecutadas y rechazadas

7.2.4 Sobrecarga vs eficiencia del sistema

7.2.5 Balance entre operarios

7.2.6 Ventajas y desventajas de cada enfoque

7.3 Discusión de resultados

Chapter 8

Conclusiones

8.1 Cumplimiento de objetivos

8.2 Conclusiones técnicas

8.3 Impacto industrial

Chapter 9

Trabajo Futuro

9.1 Optimización del algoritmo genético

9.2 Sistemas híbridos

9.3 Integración con el ERP

9.4 Pruebas con datos reales históricos

Chapter 10

Glosario

Bibliography

- [1] N. SHIVASANKARAN and P. SENTHILKUMAR. “SCHEDULING OF MECHANICS IN AUTOMOBILE REPAIR SHOPS USING ANN”. In: *IJCSE* (2014), pp. 55–56.
- [2] César Argüelles López, Ligia Herrera Franco, and Pedro Jàcome Onofre. “Estrategia de mejora al proceso productivo de Talleres Industriales de maquinados”. In: *Universo de la Tecnológica* (2018), pp. 5–6.
- [3] Kenneth C. Laudon and Jane P. Laudon. *Management Information Systems: Managing the Digital Firm*. 13th ed. Pearson, 2014.
- [4] Jairo R. Coronado-Hernandez et al. “Implementation of an E.R.P. Inventory Module in a Small Colombian Metalworking Company”. In: *Sprinter* (2019).
- [5] Rahul Malhotra, Narinder Singh, and Yaduvir Singh. “Genetic Algorithms: Concepts, Design for Optimization of Process Controllers”. In: *CCSE* (2011), p. 39.
- [6] Yunior César Fonseca Reyna and José Eduardo Márquez Delgado. “Comparación de un algoritmo genético y la técnica nube de partículas en la solución del Flow Shop Scheduling”. In: *Revista Cubana de Ciencias Informáticas* 6.4 (2012), pp. 17–26.
- [7] Alexander Alberto Correa Espinal, Elkin Rodríguez Velásquez, and María Isabel Londoño Restrepo. “Secuenciación de operaciones para configuraciones de planta tipo Flexible Job Shop: Estado del arte”. In: *Revista Avances en Sistemas e Informática* 5.3 (2008), pp. 151–161.
- [8] Wenqiang Zhang et al. “Metaheuristics for multi-objective scheduling problems in Industry 4.0 and 5.0: a state-of-the-arts survey”. In: *Frontiers in Industrial Engineering* (2025).

- [9] José David Meisel and Liliana Katherine Prado. “Un algoritmo genético híbrido y un enfriamiento simulado para solucionar el problema de programación de pedidos Job Shop”. In: *Revista EIA* (2010), pp. 39–51.
- [10] David A. Valle. “Resolución del Job Shop Scheduling Problem mediante metaheurísticas”. MA thesis. Universidad Politécnica de Madrid, 2021.
- [11] Tomal Das. “Productivity optimization techniques using industrial engineering tools: A review”. In: *ResearchGate* (2024), pp. 376–280.
- [12] Erich C. Teppan. “Types of Flexible Job Shop Scheduling: A Constraint Programming Experiment”. In: *Proceedings of the 14th International Conference on Agents and Artificial Intelligence (ICAART)*. 2022, pp. 516–523.
- [13] A. Delgado et al. “Aplicación de algoritmos genéticos para la programación de tareas en una celda de manufactura”. In: *Ingeniería e Investigación* 25.2 (2005), pp. 24–31. URL: http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0120-56092005000200003.
- [14] Aleksandar Savić et al. “Genetic Algorithm Approach for Solving the Task Assignment Problem”. In: *Serdica Journal of Computing* (2008), pp. 101–110.
- [15] J. Wang. “Application of Genetic Algorithms in Automated Mechanical Design”. In: *Proceedings of Innovative Computing 2024, Vol. 4*. 2024.